

time) Sent)



il est important d'avoir des résidus iid

↳ test de DW (= 2)

$$E[\hat{\beta}_\pi | \epsilon_{t-n}, \pi_t] = \beta_\pi + \rho \frac{\sum \epsilon_{t-n} \pi_t}{\sum \pi_t^2}$$

↓

$$\frac{\text{Cov}(\epsilon_t, \pi_t)}{V(\pi_t)}$$

Note : en présence un bruit blanc est appelé un incrément de mouvement brownien.

⇒ Misspecified un bruit "Mft"

moving average non pris en compte lorsque nos estimations

MCO & ML

Un bruit blanc est par définition stationnaire

1) X_t tel que \mathbb{H}_t , X_t and X_{t+h} have the same distribution \rightarrow hard to proof

2) X_t a time series process. Then:

- $E[X_t] = \mu \in \mathbb{D}$
- $V[X_t] = \sigma^2 \in \mathbb{D}$
- $\text{Cov}(X_t, X_{t+h}) = f(h) \in \mathbb{D}$

then Wold theorem: second order stationarity can be represent as the infinite sum of past and present shocks

$$X_t = \sum \psi_i \epsilon_{t-i} + k_t$$

Dans le cadre d'un modèle MA(1)

$$\text{autocovariance} = x_t = \rho \varepsilon_{t-1} + \varepsilon_t \quad \varepsilon_i \sim N(0, 1)$$

$$\begin{aligned}\text{Cov}(x_t, x_{t-1}) &= \text{Cov}(\rho \varepsilon_{t-1} + \varepsilon_t, \rho \varepsilon_{t-2} + \varepsilon_{t-1}) \\ &= \rho^2\end{aligned}$$


$$\text{Auto correlation} = \frac{\text{Cov}(x_t, x_{t-1})}{V(x_t)} = \frac{\rho^2 \rho}{\rho^2(n + \rho^2)} = \frac{\rho}{(1 + \rho^2)}$$

$$V(x_t) = \rho^2 V(\varepsilon_{t-1}) + V(\varepsilon_t) = \rho^2 (1 + \rho^2)$$

$$\text{auto covariance : } \text{Cov}(x_t, x_{t-2})$$

$$\begin{aligned}&= \text{Cov}(\rho \varepsilon_{t-1} + \varepsilon_t, \rho \varepsilon_{t-3} + \varepsilon_{t-2}) \\ &= \rho^2 \text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-3}) + \rho \text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-2}) + \rho \text{Cov}(\varepsilon_t, \varepsilon_{t-3}) + \text{Cov}(\varepsilon_t, \varepsilon_{t-2}) \\ &= 0\end{aligned}$$

$$\text{autocorrelation} = \frac{\text{Cov}(x_t, x_{t-h})}{V(x_t)} =$$



ils ont tous une faible
persistance

$x_t = AR(1)$

$AR(1) : x_t = \rho x_{t-1} + \varepsilon_t \sim \mathcal{N}(0, 1)$

$$\begin{aligned}
 \text{autocovariance: } \text{cov}(x_t, x_{t-n}) &= \text{cov}(e^{x_{t-n}} + \varepsilon_t, x_{t-n}) \\
 &= \rho \text{cov}(x_{t-1}, x_{t-n}) + \text{cov}(\varepsilon_t, x_{t-n}) \\
 &= \rho^2 V(x_t) + \text{cov}(\varepsilon_t, e^{x_{t-1}} + \varepsilon_{t-n}) \\
 V(x_t) &= \rho^2 V(x_{t-1}) + V(\varepsilon_t)
 \end{aligned}$$

$$\Leftrightarrow V(x_t) = \frac{\rho}{1+\rho^2}$$


$$\begin{aligned}
 \text{cov}(x_t, x_{t-2}) &= \text{cov}(e^{x_{t-1}} + \varepsilon_t, x_{t-2}) \\
 &= \rho \text{cov}(x_{t-1}, x_{t-2}) + \text{cov}(\varepsilon_t, x_{t-2}) \\
 &= \rho \text{cov}(e^{x_{t-2}} + \varepsilon_{t-1}, x_{t-2}) \\
 &= \rho \left[\text{cov}(x_t, x_{t-1}) + \text{cov}(\varepsilon_t, x_{t-1}) \right] \\
 &= \rho \left[\text{cov}(e^{x_{t-1}} + \varepsilon_t, x_{t-1}) + \text{cov}(\varepsilon_t, x_{t-1}) \right] \\
 &= \rho \cdot 0
 \end{aligned}$$

$$\Rightarrow V(x_t) = \frac{\sigma^2}{1-\rho^2} = \frac{\sigma^2 \frac{\rho^2}{1-\rho^2}}{\sigma^2/(1-\rho^2)} = \rho$$

$$\begin{aligned}\text{Cov}(x_t, x_{t-3}) &= \text{Cov}(\rho x_{t-1} + \varepsilon_t, x_{t-3}) \\ &= \rho \text{Cov}(\rho x_{t-2} + \varepsilon_{t-1}, x_{t-3}) \\ &= \rho^2 \text{Cov}(\rho x_{t-3} + \varepsilon_{t-2}, x_{t-3}) \\ &= \rho^3 V(x_t)\end{aligned}$$

$$\frac{\text{Cov}}{\sqrt{V}} = \rho^3 \neq 0 \rightarrow \frac{\text{AR persistence}}{\text{AR}(1)} \gg MA$$

Autocor



Stationnarité: AR(1): $x_t = \rho x_{t-1} + \varepsilon_t$

Sur quelles conditions le modèle AR(1) est-il stationnaire

$$\Rightarrow E[x_t] = \rho E[x_{t-1}] + \underbrace{E[\varepsilon_t]}_{=0}$$

$$\Leftrightarrow (1-\rho) E[x_t] = 0 \Leftrightarrow E[x_t] = \rho v$$

$$\textcircled{2} \quad V(x_t) = \rho^2 V(x_{t-1}) + \sigma^2$$

$$\Leftrightarrow (1 - \rho^2) V(x_t) = \sigma^2 \Leftrightarrow V(x_t) = \frac{\sigma^2}{1 - \rho^2} < \infty$$

un modèle AR(1) n'est stationnaire que si $|\rho| < 1$

Si $\rho > 1 \Rightarrow$ explosif

Si $\rho = 1 \Rightarrow x_t =$ marche aléatoire

Autocorrélation partielle

~~AR~~ $\cancel{11111111}$

décroît lentement

~~MA~~ $\cancel{11111111}$

rapide


AR(1) vs AR(2) \rightarrow difficilement différenciables à l'autocorélogramme

$$\text{AR}(n) \quad x_t = \rho_1 x_{t-1} + \dots + \rho_n x_{t-n} + \varepsilon_t \quad \begin{matrix} \varepsilon_t \sim i.i.d \mathcal{N}(0,1) \\ \rho_i \neq 0 \end{matrix}$$

$$\text{AR}(2) \quad x_t = \rho_1 x_{t-1} + \rho_2 x_{t-2} + \varepsilon_t \quad \begin{matrix} \text{Si } \rho_2 \text{ est estimé à 0} \Rightarrow \text{AR}(1) \\ \rho_2 \neq 0 \end{matrix}$$

$$\text{AR}(3) \quad x_t = \rho_1 x_{t-1} + \rho_2 x_{t-2} + \rho_3 x_{t-3} + \varepsilon_t \quad \text{Sinon: au moins un AR2}$$

$\rho \uparrow$ autocorélogramme partiel \rightarrow il ignore les autres ρ



\hookrightarrow comme l'autocorélogramme des MA

$$\text{AR}(n) = x_t = \rho x_{t-1} + \varepsilon_t$$

si $\rho > 0 \rightarrow$ Si $x_{t-n} > 0 \Rightarrow x_t > 0 \Rightarrow$ trend momentum

si $\rho < 0 \rightarrow$ Si $x_{t-1} < 0 \Rightarrow x_t < 0 \Rightarrow$ mean reversion returning to the average

estimation des modèles :

$$AR(1) = x_t = \rho x_{t-1} + \varepsilon_t \sim i.i.d N(0, 1)$$

$$\Leftrightarrow \varepsilon_t = x_t - \rho x_{t-1}$$

$$\begin{aligned} \mathcal{L}(x_t) &= \sum \varepsilon_t (x_t)^* \times \frac{\partial x_t}{\partial x_t} \\ &= \frac{1}{\sqrt{2\pi/\sigma^2}} \end{aligned}$$

⋮

$$f(x_1, \dots, x_n) = \left[\prod_{i=2}^n f(x_i | x_{i-1}) \right] \times f(x_1)$$

$$\max \log \mathcal{L} = \sum_{i=2}^n \log f(x_i | x_{i-1})$$

$$\max \log \mathcal{L} = -(n-1) \log (\sqrt{2\pi/\sigma^2}) - \frac{1}{2} \sum_{i=2}^n \left(\frac{x_i - \rho x_{i-1}}{\sigma} \right)^2$$

minimisation
des moindres
carrés

$$(Mt) \quad x_t = \rho x_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim i.i.d N(0, \sigma^2)$$

ensemble concentré

$$\underline{\underline{TCL}} = \underline{\underline{f(x_t)}} = \frac{1}{\sqrt{2\pi/\sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{x_t - \rho x_{t-1}}{\sigma} \right)^2 \right]$$

$$f(x_t | \varepsilon_{t-1})$$

pour obtenir $\varepsilon_{t-1} \rightarrow \rho, \sigma^2$

pour obtenir $\rho, \sigma^2 \rightarrow \varepsilon_{t-1}$

de problème:
je peux conditionner $x_t | \varepsilon_{t-1}$

MAIS: ε_t reste inconnue

On se donne une valeur pour ρ, σ^2

$$\varepsilon_1 = 0 \quad \leftarrow \text{départ}$$


$$x_2 = \rho \varepsilon_1 + \varepsilon_2 \Rightarrow \varepsilon_2 = x_2 - \rho \varepsilon_1 = x_2$$

$$x_3 = \rho \varepsilon_2 + \varepsilon_3 \Rightarrow \varepsilon_3 = x_3 - \rho \varepsilon_2$$

$$x_4 = \underline{\underline{\quad}}$$

$$\varepsilon_4 = \underline{\underline{\quad}}$$

je peux
calculer la série
des ε_i associés





$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i | \varepsilon_{i-1})$$

$$\log f(x_1, x_2, \dots, x_n | e, \partial_e) = \sum \log f(x_i | \varepsilon_{i-1}, \partial_e)$$

$$= -(n-n) \ln (\sqrt{8\pi} \partial_e) - \frac{1}{2} \sum_i \left(\frac{x_i - \rho_{\varepsilon_{i-1}}}{\partial_e} \right)^2$$

$\frac{\partial \log f}{\partial e} \Rightarrow$ optimisation numerique

Choose p, q with AIC - BIC and HQ



Si $f(b) < f(a)$

$$a \rightarrow \frac{b+a}{2}$$

Si $f(b) > f(a) \Rightarrow b \rightarrow \frac{b+a}{2}$

On se rapproche

At Projet max 30 Mars \rightarrow PDF sinon pas note' issue
d'un notebook le plus exigeant

\rightarrow pas copier mais c'est bien de chercher sur wikipedia

la doc excel proxies de volatility et rendement journaliers au carré

modèle AR: bon ordre \rightarrow diversi de estimation même

estimations 15/16 / 20

montrer qu'on a compris 20%.

On a 3 séries le AR HAR etc

On a 3 mesures de risque:
qui doivent homogénéiser
+ AR et HAR pour filtrer les
séries

VAR \rightarrow un choc dans une série a un
impact dans une autre série.

Previously

- 1) Rappel d'estimation
- 2) AR(1)~~MAX~~ → AR le + important
- 3) stationnarité & AR multivariée

Q) AR

- 1) spécification
- 2) identification / ACF/PACF estimation
- 3) Application en finance
 - a) Efficacité Marché ETM
 - b) Volatilité
 - c) taux

→ Comme efficacité des Marchés, pas de signif. du modèle AR
 $r_t = \hat{\rho}_0 + \hat{\rho}_1 r_{t-1} + \hat{\sigma} \epsilon_t$
 si o pas de gain d'argent pas de dépendance temporelle

Volatilité

$$\hat{V}(r_t) = \frac{1}{n} \sum_{i=1}^n (r_t - \bar{r})^2 \text{ estimation des moments}$$

quel N? tous les rendements passé ont la même contribution

redistributive, ou en veut pas

Solution: poids devant les r

\Rightarrow risque = variance \Rightarrow estimation (mesure)
 (inobservable)

2 Solutions


1) AR sur les rendements au carré

$$r_t^2 = \phi_0 + \phi_1 r_{t-1}^2 + \dots + \phi_p r_{t-p}^2 + \sigma \epsilon_t^n$$

$\epsilon_t \sim \text{BB gaussien}$

$$E[r_t^2] = V[r_t^2] \quad \text{si } \mu = 0$$

2) Poursuivons intraday



découpage de la journée entre 5 et 15 min par ex

$$\hat{V}[r_t] = \sum_{i=N}^0 r_t - \bar{s}_i^2$$

↑
petit pas de temps égal à δ

PQ somme et pas moyenne?

RQ: ① on somme variance journalière

si on divise on aurait la variance à 5 min

$$\hat{V}[r_t] = \frac{1}{N+1} \sum_{i=1}^N r_t - \bar{s}_i^2$$

à 5 min

la variance annuelle

$$\text{Vannuelle} = 252 \times V_{\text{journalière}}$$

$$\text{Volatilité: } \sqrt{\text{Vannuelle}} = \sqrt{252} \times \sqrt{V_{\text{journalière}}}$$

On modélise pas la volatilité mais la variance car elle a un lien naturel avec le carré des rendements et la volatilité avec la valeur absolue.

$$\text{HAR} \Rightarrow \hat{V}[r_t] = f \left(\sum_{i=N}^0 r_{t-i\delta} \right)$$

Modèle GARCH

$$\rightarrow r_t = \alpha + \epsilon_t$$

AR + une fonction r_{t-1}^2

Si bcp de volatilité il faut décomposer le bruit

Corsi : lissage de l'estimation de la volatilité

Comme si trois bruit
 day, week, monthly
 ↓
 le plus important
 le moins
 spéculateur

Une des difficultés des modèles des variances lors de l'estimation

\rightarrow la variance doit rester positive

Solution : log ? par corsi je crois

Engel le prend pas en compte

ça dépend de β dans

$$\sigma_t^2 = w + \alpha \dots + \beta \sigma_{t-1}^2$$

Contrainte des mesures de volatilité

achat séries de données \rightarrow hyper cher

\rightarrow NOKT pour avoir le midday

estimateur de Parkinson et farman Klass pour relier l'un à l'autre
 open low high and close
 \rightarrow day to intraday

OHC

on relie les points max et min intraday avec open and close

$$\sigma_{ML}^2 = \frac{1}{4 \log 2} \left[\log \left(\frac{H_t}{L_t} \right) \right]^2$$

Brownian Klasse \rightarrow similaire \oplus complexe

$$\sigma_{t+h, k}^2 = \frac{\alpha}{f} \left[\log \frac{S_t}{C_{t+n}} \right]^2 + \frac{1-\alpha}{1-f} \frac{1}{\log 2} \left[\log \frac{S_t}{K_t} \right]^2$$

↓
temps entre open and close

Parkinson mesure très velâtre donc il faut découper le BB de l'yo.

Black and Scholes (BS)

$$\frac{dS_t}{S_t} = \underbrace{rf dt}_{BB} + \theta dW_t^P$$

sous IP → dynamique historique très sensée

pas sous P

$$\frac{dS_t}{dt} = \underbrace{rf}_{Q} dt + \theta dW_t^Q$$

la volatilité θ ne change pas sous IP et Q

le seul changement c'est le taux sans risque

$$C(k, S, T-t, r, \theta) = S \sqrt{V(d_1)} - \alpha e^{-r(T-t)} N(d_2)$$

$$\rightarrow C^T \min \left(C^u - e^{B^*} \right)$$

sous devol

en fait, $\theta^P \neq \theta^Q$
on change la volatility

risk neutral volatility

similaire à avoir plein d'infos intraday

$$\mathbb{E} \left[\int_0^T \left(\frac{dF_t}{F_t} \right)^2 \right] \rightarrow \text{somme des différences de rendement au carré}$$

somme en continu \rightarrow calcul de variance si rendements proches de 0
 $r_t \sim 0$

Variance risque neutre

\rightarrow Pas de volatility (personne le fait !)

volatilité moyenne les portefeuilles entraux

volatilité BS $\rightarrow 20\%$

\neq variance risque neutre = 20%

Quel échelle de temps ?
 toujours annuelle

volatilité annualisé de l'ordre de 20% !

Parkinson : variance journalière

\neq annualisé \neq mesure risque

volatilité moyenne entre 15% et 20%

hs 80% ou plus pas sur

$$\boxed{\text{Variance}} \times \sqrt{250} \times 100 \rightarrow \text{par pourcentage} = \text{volatilité}$$

Si volatilité 100% rendements + 0 - 200%

$$[-100\%; +100\%]$$

hs on peut tout perdre

Pourquoi récupère la bourse ?

estimation des paramètres pour Max de l'ajustement
 test Student pour la significativité donc estimation

horsien ne prend la diag
inverse et la racine pour avoir le
std et non la significativité
Variance formelle très petite
donc log var est négative

From Data to Signals.

- Stationarity Tests - VAR models

Quelle est l'hypothèse nulle de DF-ADF?

Dans les modèles VAR, il faut retenir les gts de réponses impulsionnelles

Modèle VAR = Économétrie de modèles non stationnaires.

Partie python dans le 1er script python

En quoi la marche aléatoire "vole" l'hyp de stationnarité?

Stationnarité au 1^{er} dégré : espérance, variance et covariance finie en fonction du temps.

On utilise le modèle Wald.

Revenons au concept de marche aléatoire :

$$\underbrace{P_t}_{\text{Marche actuelle}} = \underbrace{P_{t-1}}_{\text{Marche précédent}} + \underbrace{\sigma \epsilon_t}_{\text{incrément}} \Rightarrow E[P_t] = E[P_{t-1}] + \sigma E[\epsilon_t]$$

→ la meilleure prévis' qu'on puisse donner à P_t c'est son passé.

⇒ NON-STATIONNAIRE

Une façon de comprendre la non stationnarité de la marche aléatoire c'est le modèle AR

$$X_t = \delta X_{t-1} + \varepsilon_t \text{ avec } \varepsilon \sim \text{BFG gaussien}$$

$$\delta \rightarrow 1$$

$\hookrightarrow \delta = 1$: Processus intégré d'ordre 1

Dég: Processus intégré d'ordre 1.

$X_t \in I(1)$ ssi: 1) X_t non stationnaire
2) $\Delta X_t = X_t - X_{t-1}$ est stationnaire

IMA (marche aléatoire) est apprécier

car on peut faire passer un modèle AR \rightsquigarrow IMA

\hookrightarrow Idée sous-jacente de Dickey-Fuller

Intuit° de DF:

$$X_t = \rho_0 + \rho_1 X_{t-1} + \varepsilon_t$$

$\varepsilon_t \sim \text{BFG}$

Une façon de tester la non stationnarité revient à faire un "test de Student" pour $\rho_1 - 1$

$\left\{ \begin{array}{l} H_0: \text{Non stationnarité} \rightarrow \rho_1 = 1 \\ H_1: \text{Stationnaire sinon} \end{array} \right.$

Si je clegemène une Moving Average vers la chose le + statut et proche, c'est un AR(1)

Moving Average \rightarrow Non stationnaire + Non explicatif

?

Marche aléatoire :

1) Non stationnaire

2) Non explosive : $E(P_t | P_{t-1}) = P_{t-1}$

$$E(P_{t+1} | P_{t-1}) = P_{t-1}$$

$$E(P_{t+\ell} | P_{t-1}) = P_{t-1}$$

Dans DF, on teste si le modèle a une tendance ex/ou constant

1) $P_t = \hat{\delta} P_{t-1} + \mu + \lambda_t + \epsilon_t$

2) $P_t = \hat{\delta} P_{t-1} + \mu + \epsilon_t$

$$P_t = \hat{\delta} P_{t-1} + \epsilon_t$$

Remarque : 1) Si P_t est stationnaire alors $\sqrt{n}(\hat{\delta} - \delta_0) \sim N(0, \Sigma)$

2) Si P_t non stationnaire alors on connaît pas la distrib^o de $\hat{\delta}$.

\Rightarrow Test DF / ADF:

$$\left\{ \begin{array}{l} H_0: \hat{\delta} = 1 \\ H_1: \hat{\delta} \neq 1 \quad \hat{\delta} < 1 \\ \hat{\delta} \sim ? \text{ "tabule"} \end{array} \right.$$

Remarque: $\left\{ \begin{array}{l} p_t = \delta p_{t-1} + \varepsilon_t \\ \text{Et } p_0 \text{ fixé} \end{array} \right.$

Si $\delta < 1 \Rightarrow$ stationnaire

Si $\delta = 1 \Rightarrow$ marche aléatoire

Si $\delta > 1 \Rightarrow$ explosif \rightarrow On modifie rien d'exploit.

On part d'un processus stationnaire

L'estimat° de la valeur de δ , on le fait par les MCO

\hookrightarrow Pas d'hypothèses douces garanties.

$$\hat{\delta}_1 = \frac{\sum_{t=1}^T p_{t-1} p_t}{\sum_{t=1}^T p_{t-1}^2}$$

Pour regarder la distribut°, on commence par regarder l'écart
p1 le paramètre et sa valeur.

$$\Rightarrow \hat{\delta}_1 - \delta_1 = \frac{\sum_{t=1}^T p_{t-1} (\hat{\delta}_1 p_{t-1} + \varepsilon_t)}{\sum_{t=1}^T p_{t-1}^2}$$

$$= p_1 \frac{\cancel{\sum p_{t-1}^2}}{\sum p_{t-1}^2} + \frac{\sum p_{t-1} \varepsilon_t}{\sum p_{t-1}^2}$$

$$\Rightarrow \hat{\delta}_1 - \delta_1 = \frac{\sum_{t=1}^T p_t \varepsilon_t}{\sum_{t=1}^T p_{t-1}^2} \Rightarrow \hat{\delta}_1 \text{ est un estimateur super cohérent de } \delta_1$$

Dickey Fuller tabulent leur fois assuming normal distribut°

↳ ADF est un modèle où les ϵ_t sont persistants.

\Rightarrow DF: ϵ_t PPG

ADF: $u_t + \rho u_{t-1} + \epsilon_t$

Hypothèses: On a un drift stochastique dans une série temp qui est une marche aléatoire aussi longtemps que la volatilité d' $\epsilon_t = 0$.

Modèle de Vasicek \rightarrow Modèle de retour vers la moyenne.

$$dr_t = K(\theta - r_t) dt + \sigma dw_t$$

Valeur de long terme de r_t
force de rappel

$$\Leftrightarrow r_{t+1} - \gamma = K\theta - Kr_t + \sigma \epsilon_t$$

(discrétisat°
d'Euler)

avec ϵ_t PPG

$$\Leftrightarrow r_{t+1} = Kr_t + (1-K)\theta + \sigma \epsilon_t$$

$$\Leftrightarrow r_{t+1} = \rho_0 + \rho_1 r_t + \sigma \epsilon_t$$

gène la persistance des chocs du modèle

↳ C'est un modèle AR(1) stationnaire \rightarrow On suppose que les taux d'intérêts sont stationnaires

↳ Ce modèle suppose assez mal la notion de stationnarité

Les modèles VAR:

AR

$$x_t = \phi_0 + \phi_1 x_{t-1} + \epsilon_t$$

VAR: Vectorial Auto Régression

$$x_t = \Phi_0 + \Phi_1 x_{t-1} + \sum \epsilon_t$$

$m_{m,1}$ $m_{m,2}$ $m_{m,m}$ $m_{m,1}$ $m_{n,n}$ $m_{n,1}$

m est le nombre de variables à modéliser conjointement

$$\Rightarrow \begin{pmatrix} x_t^{(1)} \\ x_t^{(2)} \\ \vdots \\ x_t^{(n)} \end{pmatrix} = \begin{pmatrix} \Phi_0^{(1)} \\ \Phi_0^{(2)} \\ \vdots \\ \Phi_0^{(n)} \end{pmatrix} + \begin{pmatrix} \Phi_1^{(1)} & \cdots & \Phi_{1,n} \\ \vdots & \ddots & \vdots \\ \Phi_{1,1} & \cdots & \Phi_{1,n} \end{pmatrix} + \begin{pmatrix} a^{(1)} \\ a^{(2)} \\ \vdots \\ a^{(n)} \end{pmatrix} + \begin{pmatrix} \varepsilon_t^{(1)} \\ \varepsilon_t^{(2)} \\ \vdots \\ \varepsilon_t^{(n)} \end{pmatrix}$$

+ m'est pas symétrique

$$\Sigma = \Phi \Phi^T \Rightarrow \sqrt{\Sigma} = \Phi$$

↳ Ce n'est pas la racine des élém^r de Σ .

$$\Sigma = \begin{pmatrix} \sigma^{(1,1)} & \sigma^{(1,n)} \\ \sigma^{(n,1)} & \sigma^{(n,n)} \end{pmatrix}$$

Dans le cas 2×2 :

$$\begin{pmatrix} x_t^{(1)} \\ x_t^{(2)} \end{pmatrix} = \begin{pmatrix} \Phi_0^{(1)} \\ \Phi_0^{(2)} \end{pmatrix} + \begin{pmatrix} \Phi_1^{(11)} & \Phi_1^{(12)} \\ \Phi_1^{(21)} & \Phi_1^{(22)} \end{pmatrix} \begin{pmatrix} x_{t-1}^{(1)} \\ x_{t-1}^{(2)} \end{pmatrix} + \begin{pmatrix} a \\ c \end{pmatrix} \begin{pmatrix} \varepsilon_t^{(1)} \\ \varepsilon_t^{(2)} \end{pmatrix}$$

$$x_t^{(1)} = \underbrace{\Phi_0^{(1)}}_{\text{AR}(1)} + \underbrace{\Phi_1^{(11)} x_{t-1}^{(1)}}_{\text{multivarié}} + \underbrace{\Phi_1^{(12)} x_{t-1}^{(2)}}_{\text{multivarié}} + \underbrace{a \varepsilon_t^{(1)}}_{\text{choc / "innovat")}} + \underbrace{b \varepsilon_t^{(2)}}_{\text{choc / "innovat")}}$$

$$x_t^{(2)} = \underbrace{\Phi_0^{(2)}}_{\text{pas instantané}} + \underbrace{\Phi_1^{(21)} x_{t-1}^{(1)}}_{\text{"choc" / "innovat")}} + \underbrace{\Phi_1^{(22)} x_{t-1}^{(2)}}_{\text{"choc" / "innovat")}} + \underbrace{c \varepsilon_t^{(1)}}_{\text{choc / "innovat")}} + \underbrace{d \varepsilon_t^{(2)}}_{\text{choc / "innovat")}}$$

avec $\varepsilon_t^{(1)}$ et $\varepsilon_t^{(2)}$ sont des RRG non corrélés

Remarque: • Si $\Sigma = \begin{pmatrix} \sigma_n & 0 \\ 0 & \sigma_n^2 \end{pmatrix} \Rightarrow$ le choc de $x_t^{(1)}$ et de $x_t^{(2)}$ sont décorrélés.

• Si $\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{pmatrix} \Rightarrow$ les valeurs ● sont supérieures aux valeurs ●

\Rightarrow le choc dominant

de $x_t^{(1)}$ c'est $\varepsilon_t^{(1)}$
 $x_t^{(2)}$ $\varepsilon_t^{(2)}$

On passe maintenant au VAR(p), dans le cas où on a n séries de données

$$X_t = \Phi_0 + \sum_{l=1}^p \Phi_{l,i} \cdot X_{t-l} + \sqrt{\sum_{n,n}^{n,1}} \epsilon_t$$

intercept : n

autoregression : n · n · p

covariance : $\frac{n(n-1)}{2}$

→ $n \left[pm + 1 + \frac{m-1}{2} \right]$ paramètres à estimer

Exemple : 2 logs et 2 séries ⇒ n = séries { 1 } paramètres à estimer
p = 1 log

Estimation des logs :

Parenthèse

VAR servent dans 2 cas :

1) IRF : Le choc d'une frite se répercute de façon sép.
dans les autres séries.

↳ Banque centrale

2) Macro-financé : $P_t = E^Q (\text{Cashflow}_t)$

↳ Forme de VAR

1) VAR(p) → $\Pi L / \Pi CO$

$$X_t = \Phi_0 + \Phi_1 X_{t-1} + \sqrt{\sum} \epsilon_t$$

La modélisation d'un modèle VAR est un système de retour à la moyenne

⇒ Tjr modéliser les séries que stationnaire

Select° de l'ordre :

↳ Avec les critères d'information.

⇒ On doit regarder AIC BIC HQ.

Impulse Response Functions:

↳ Étude de l'impact d'un choc d'une variable sur un set d'autres variables

On veut mesurer l'impact d'un choc sur la série X_t^1 sur la série X_t^2

Pour y arriver, on a besoin de 2 choses.

- Stationnarité pour travailler avec ces chocs
- Identifier ces chocs.

$$\textcircled{1} \quad X_t^1 = f(\varepsilon_{t-1}^1, \varepsilon_{t-2}^1, \dots)$$

X_t^1 comme une fct° de chocs passés

↳ Si X_t stationnaire, on peut appliquer le th. de Wold :

$$X_t = \sum_{i=0}^{\infty} \Delta_i \sqrt{\sum} \varepsilon_{t-i}$$

X_t est la somme de chocs passés

$$\rightarrow E[X_{t+h} | X_t] = f(X_t, \varepsilon_t)$$

$$X_t = \phi_0 + \phi_1 X_{t-1} + \sqrt{s} \varepsilon_t$$

$$E(X_{t+h}) \text{ et } \varepsilon_t$$

$$\textcircled{2} \quad \hat{x}_t^1 = \phi_0 + \alpha R + \hat{\phi}_1 \hat{x}_t^2 + a \hat{\varepsilon}_t^1 + b \hat{\varepsilon}_t^2$$

$$\hat{x}_t^2 = \frac{\varepsilon_t^1}{\varepsilon_t^1 \wedge \varepsilon_t^2} + c \hat{\varepsilon}_t^1 + c \hat{\varepsilon}_t^2$$

$$\begin{array}{c} \varepsilon_t^1 \\ \swarrow \quad \searrow \\ \varepsilon_t^1 \quad \varepsilon_t^2 \end{array}$$

⇒ On veut créer des chocs orthogonaux, décorrélés les uns des autres.

On veut pas ça, des chocs simultanés

Pour y arriver, on utilise une décomposition de Choleski.

Si Σ est une matrice symétrique, alors il existe une matrice définie \oplus telle que:

$$PP^T = \Sigma \text{ avec } P \text{ une matrice triangulaire inférieure.}$$

$$P = \begin{pmatrix} P_{11} & & \\ P_{12} & P_{22} & \\ P_{13} & P_{23} & P_{33} \\ \vdots & \ddots & \ddots \end{pmatrix}$$

$$\varepsilon_t \sim N(0, \Sigma)$$

$$u_t = P^{-1} \varepsilon_t \quad , \quad PP^T = \Sigma$$

on va définir de nouvelles innovations.

3 caractéristiques :

$$1) \varepsilon_t \sim N(0, \Sigma) \Rightarrow u_t \sim N(0, I)$$

$$2) E[u_t] = E[P^{-1} \varepsilon_t] = P^{-1} E[\varepsilon_t] = 0$$

$$\begin{aligned} 3) V[u_t] &= E[u_t u_t^T] = E[P^{-1} \varepsilon_t \varepsilon_t^T P^{-1}] \\ &= P^{-1} E[\varepsilon_t \varepsilon_t^T] P^{-1} \\ &= P^{-1} P P^T P^{-1} = I \end{aligned}$$

$$X_t = \bar{X}_0 + \Delta_1 \varepsilon_{t-1} + \Delta_2 \varepsilon_{t-2} + \dots$$

$$= \bar{X}_0 + \Delta_1 P u_{t-1} + \Delta_2 P u_{t-2} + \Delta_3 P u_{t-3} + \dots$$

définition: une "impulsion réponse fonction" est une fonction qui associe :

$$h \longmapsto \frac{\partial X_{t+h}}{\partial M_t}$$

Projet :

on a des volatilités Mais on doit mobiliser
des variations \rightarrow stationnaires

1 jour sur l'année
1 mois sur l'année

impact de mesure de volatilité n'importe
ou historiques.